

1_Data_Preprocessing_3

August 11, 2026

0.1 1. Pembacaan dan Inspeksi Data Mentah (*Data Ingestion & Initial Profiling*)

Tujuan Akademis: Mengenali struktur kolom, tipe data, serta mengeksplorasi secara “buta” apa saja isi dari data mentah yang diekspor langsung oleh sistem WhatsApp. **Tindakan:** Memuat file `master_chat_wa.csv` ke dalam *DataFrame*, melihat ringkasan informasi kolom, memeriksa cuplikan baris pertama, dan menampilkan frekuensi isi pesan untuk mendeteksi adanya anomali atau *noise*.

```
[4]: import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings('ignore')

print("=== TAHAP 1: DATA MENTAH ===")

# 1. Membaca data mentah
df_raw = pd.read_csv('master_chat_wa.csv')

# 2. Inspeksi struktur data (melihat ada kolom apa saja dan tipe datanya)
print("--- 1. Informasi Struktur Dataset Mentah ---")
df_raw.info()

# 3. Melihat wujud datanya secara langsung
print("\n--- 2. Cuplikan 5 Baris Pertama Dataset ---")
display(df_raw.head())

# 4. Inspeksi sampel data pada kolom isi pesan (Message Body)
print("\n--- 3. Top 15 Isi Pesan Terbanyak (Deteksi Noise) ---")
print(df_raw['Message Body'].value_counts().head(15))
```

```
=== TAHAP 1: DATA MENTAH ===
--- 1. Informasi Struktur Dataset Mentah ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3502 entries, 0 to 3501
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Country                3502 non-null   object
```

```

1  Phone Number    3502 non-null    int64
2  Formatted Name  3502 non-null    object
3  Display Name    3418 non-null    object
4  Message Time    3502 non-null    object
5  Message Type    3502 non-null    object
6  Message Body    3447 non-null    object
7  Message Id      3502 non-null    object
dtypes: int64(1), object(7)
memory usage: 219.0+ KB

```

--- 2. Cuplikan 5 Baris Pertama Dataset ---

	Country	Phone Number	Formatted Name	Display Name \
0	Indonesia	6285752887496	Anda	anugerahcomputer4
1	Indonesia	6285752887496	Anda	anugerahcomputer4
2	Indonesia	6281156701235	+62 811-5670-1235	NaN
3	Indonesia	6281156701235	+62 811-5670-1235	NaN
4	Indonesia	6285752887496	Anda	anugerahcomputer4

	Message Time	Message Type	Message Body \
0	2026-04-27 12:10:50	chat	IMAGE
1	2026-04-27 12:10:55	chat	Anugerah komputer
2	2026-04-27 16:13:57	chat	Oke bg
3	2026-04-29 10:17:27	chat	Bg berapa kemarin harganya ya
4	2026-04-29 10:18:06	chat	Nnti tnya y bg blom dtg bos nya

	Message Id
0	true_211622366855206@lid_AC2292D9378555369E125...
1	true_211622366855206@lid_ACEC981E86F9304411889...
2	false_211622366855206@lid_ACCC7B568284EA7BDECA...
3	false_211622366855206@lid_AC0056ED0CC9DBDAF77A...
4	true_211622366855206@lid_AC4ECED0F39172D7E0788...

--- 3. Top 15 Isi Pesan Terbanyak (Deteksi Noise) ---

Message Body	
IMAGE	331
Anugerah komputer	59
Oke kak	45
Ok	41
Oke bang	36
Iya kak	24
Ok bg	17
Anugerah Computer	16
Ok kk	15
Okee kak	15
Oke bg	14
VIDEO	13
Bisa kak	13

```
oke bang          11
Iya bang          7
Name: count, dtype: int64
```

0.2 2. Penyaringan Teks dan Pembuangan Derau (*Data Filtering & Noise Removal*)

Tujuan Akademis: Memisahkan data teks murni yang relevan untuk analisis dari data yang tidak berguna bagi model. **Tindakan Berdasarkan Hasil Inspeksi:** 1. Berdasarkan struktur kolom `Message Id`, kita mengidentifikasi bahwa pesan masuk dari pelanggan diawali dengan `false_`. Maka, kita filter khusus awalan ini. 2. Berdasarkan inspeksi isi pesan, ditemukan adanya data multimedia (seperti `IMAGE` atau `VIDEO`). Karena model NLP kita hanya memproses teks, semua baris yang mengandung pola kurung siku tebal ... akan dihapus menggunakan *Regular Expression* (RegEx). 3. Menghapus baris kosong (NaN). Sesuai dengan strategi mempertahankan distribusi data alami, penghapusan duplikasi belum dilakukan pada tahap ini.

```
[5]: import re

print("=== TAHAP 2: PENYARINGAN & PEMBUANGAN DERAU ===")

# Tindakan 1: Filter HANYA pesan pelanggan (inbound)
df_customer = df_raw[df_raw['Message Id'].astype(str).startswith('false_')].
    ↪copy()
print(f"- Jumlah pesan pelanggan saja (false_): {len(df_customer)} baris")

# Tindakan 2: Hapus pesan non-teks (gambar, video, dokumen, dll yang
    ↪menggunakan format ...)
noise_pattern = r' .*? '
df_customer = df_customer[~df_customer['Message Body'].astype(str).
    ↪contains(noise_pattern, regex=True)]

# Tindakan 3: Menghapus pesan yang kosong (NaN/Null)
df_unique = df_customer.dropna(subset=['Message Body']).copy()

# Catatan: Baris drop_duplicates dimatikan (tidak dieksekusi) agar frekuensi/
    ↪distribusi asli chat tetap terjaga
# df_unique = df_customer.drop_duplicates(subset=['Message Body']).copy()

print(f"\nHasil Penyaringan: Ditemukan {len(df_unique)} baris pesan teks
    ↪pelanggan siap diproses.")
```

```
=== TAHAP 2: PENYARINGAN & PEMBUANGAN DERAU ===
- Jumlah pesan pelanggan saja (false_): 1719 baris
```

Hasil Penyaringan: Ditemukan 1581 baris pesan teks pelanggan siap diproses.

0.3 3. Pembersihan Teks Dasar (*Basic Text Cleaning*)

Tujuan Akademis: Menyeragamkan format huruf dan menghilangkan karakter asing yang tidak memberikan nilai semantik bagi algoritma mesin. **Tindakan:** Mengubah seluruh teks menjadi huruf kecil (*case folding*), serta menghapus tautan internet (URL), angka, dan tanda baca menggunakan *Regular Expression* (RegEx) sehingga hanya menyisakan karakter alfabet dan spasi tunggal. Data yang kalimatnya menjadi kosong setelah dibersihkan (misalnya pesan yang hanya berisi angka atau emoji) akan dibuang.

```
[6]: import re

print("=== TAHAP 3: PEMBERSIHAN TEKS DASAR ===")

def clean_text(text):
    text = str(text).lower() # Case folding (semua huruf kecil)
    text = re.sub(r'http\S+|www\S+|https\S+', '', text, flags=re.MULTILINE) #_
    ↪Hapus URL/Link
    text = re.sub(r'[^a-z\s]', '', text) # Hapus karakter non-alfabet (angka, _
    ↪simbol, tanda baca)
    text = re.sub(r'\s+', ' ', text).strip() # Hapus spasi ganda
    return text

# Menerapkan fungsi cleaning ke kolom baru 'Cleaned_Message'
df_unique['Cleaned_Message'] = df_unique['Message Body'].apply(clean_text)

# Membuang baris yang teksnya menjadi kosong setelah dibersihkan
# (Misal: pesan asli hanya berisi emoji " " atau angka "1")
df_unique = df_unique[df_unique['Cleaned_Message'] != '']

print(f"Berhasil dibersihkan! Tersisa {len(df_unique)} baris teks murni.")
print("\n--- Pratinjau Teks Asli vs Teks Bersih ---")
display(df_unique[['Message Body', 'Cleaned_Message']].head(10))
```

```
=== TAHAP 3: PEMBERSIHAN TEKS DASAR ===
```

```
Berhasil dibersihkan! Tersisa 1568 baris teks murni.
```

```
--- Pratinjau Teks Asli vs Teks Bersih ---
```

```

                                Message Body \
2                                Oke bg
3                                Bg berapa kemarin harganya ya
5                                Okey bg
7                                Tutup jam brp bg
9                                Okey bg bntr lagi saya kesana
10                               Saya otw kesana bg
12  misa bg sya kemarin servis laptop ditempat abg...
14  abg buka nd yah hari ini saya antar laptop lgi
16                                oke nnti saya bawa
18  bg mau tanya laptop nya udh betul belum
```

```

Cleaned_Message
2             oke bg
3         bg berapa kemarin harganya ya
5             okey bg
7             tutup jam brp bg
9         okey bg bntr lagi saya kesana
10            saya otw kesana bg
12 misa bg sya kemarin servis laptop ditempat abg..
14     abg buka nd yah hari ini saya antar laptop lgi
16            oke nnti saya bawa
18            bg mau tanya laptop nya udh betul belum

```

0.4 4. Pelabelan Heuristik Awal (*Initial Rule-Based Labeling*)

Tujuan Akademis: Membuat hipotesis label kelas awal secara otomatis sebelum diverifikasi oleh pakar (peneliti). Proses ini akan mempercepat dan mempermudah peneliti dalam melakukan validasi manual (*Ground Truth*). **Tindakan:** Memberikan label secara heuristik menggunakan kamus kata kunci lokal (*keyword dictionary*) untuk kelas *setuju* dan *batal*. Kalimat yang tidak memuat satupun kata kunci tersebut akan otomatis diklasifikasikan ke dalam kelas *lainnya*.

```

[13]: print("=== TAHAP 4: PELABELAN HEURISTIK AWAL ===")

def initial_label(text):
    # Kamus kata kunci lokal khas Pontianak/Indonesia
    keywords_setuju = ['lanjut', 'setuju', 'sikat', 'oke', 'boleh', 'iyak', '
↳ 'ganti', 'kerjakan', 'aman', 'gas']
    keywords_batal = ['batal', 'cancel', 'ndak usah', 'kemahalan', 'mahal', '
↳ 'ndak jadi', 'nanti dolok']
    # Deteksi berdasarkan kata kunci
    if any(word in text for word in keywords_batal):
        return 'batal'
    elif any(word in text for word in keywords_setuju):
        return 'setuju'
    else:
        return 'lainnya'

# Menerapkan fungsi pelabelan awal
df_unique['Intent_Awal'] = df_unique['Cleaned_Message'].apply(initial_label)

print("Berhasil memberikan label sementara.")
print("\n--- Pratinjau Teks Bersih dan Label Awal ---")
display(df_unique[['Cleaned_Message', 'Intent_Awal']].head(10))

print("\n--- Distribusi Label Sementara ---")
print(df_unique['Intent_Awal'].value_counts())

```

=== TAHAP 4: PELABELAN HEURISTIK AWAL ===

Berhasil memberikan label sementara.

--- Pratinjau Teks Bersih dan Label Awal ---

	Cleaned_Message	Intent_Awal
2	oke bg	setuju
3	bg berapa kemarin harganya ya	lainnya
5	okey bg	setuju
7	tutup jam brp bg	lainnya
9	okey bg bntr lagi saya kesana	setuju
10	saya otw kesana bg	lainnya
12	misa bg sya kemarin servis laptop ditempat abg..	lainnya
14	abg buka nd yah hari ini saya antar laptop lgi	lainnya
16	oke nnti saya bawa	setuju
18	bg mau tanya laptop nya udh betul belum	lainnya

--- Distribusi Label Sementara ---

```
Intent_Awal
lainnya      1145
setuju       389
batal        34
Name: count, dtype: int64
```

0.5 5. Ekspor Data untuk Validasi Manual (*Ground Truth Validation*)

Tujuan Akademis: Menghindari label palsu/salah (*False Labeling*) yang dihasilkan dari skrip otomatis berbasis aturan (karena keterbatasan pendeteksian kata). Validasi manual oleh peneliti (*Human-in-the-loop*) bertindak sebagai kontrol kualitas mutlak (pembuat *Ground Truth*) sebelum data dilanjutkan ke tahap analisis ketidakseimbangan kelas dan pemodelan AI. **Tindakan:** Menyimpan dataset yang telah dilabeli sementara ke dalam format CSV agar dapat dikoreksi di luar sistem, misalnya menggunakan *spreadsheet*.

```
[14]: print("=== TAHAP 5: EKSPOR DATA UNTUK VALIDASI MANUAL ===")

# Mempersiapkan format ekspor (hanya mengambil kolom yang dibutuhkan untuk
    ↳ validasi)
df_export = df_unique[['Message Time', 'Display Name', 'Message Body',
    ↳ 'Cleaned_Message', 'Intent_Awal']].copy()

# Mengubah nama kolom agar mudah dibaca di Excel
df_export.rename(columns={
    'Message Body': 'Teks_Aslis',
    'Intent_Awal': 'Label_Validasi'
}, inplace=True)

# Ekspor ke CSV
file_validasi = 'data_mentah_untuk_validasi.csv'
```

```
df_export.to_csv(file_validasi, index=False)

print(f" HASIL: Data berhasil diekspor ke '{file_validasi}'.")
```

=== TAHAP 5: EKSPOR DATA UNTUK VALIDASI MANUAL ===

HASIL: Data berhasil diekspor ke 'data_mentah_untuk_validasi.csv'.

0.6 6. Analisis Data Eksploratif Pasca-Validasi (*Post-Validation EDA*)

Tujuan Akademis: Mendiagnosis kondisi distribusi kelas (*Class Distribution*) setelah label dipastikan 100% benar secara empiris (telah divalidasi manual oleh peneliti sebagai *Ground Truth*).

Tindakan: Membaca kembali file `data_mentah_untuk_validasi.csv` yang telah direvisi, menstandarisasi teks label (berjaga-jaga dari *human error* pengetikan spasi/huruf besar di Excel), kemudian memvisualisasikan jumlah data per kelas niat (*intent*).

```
[15]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

print("=== TAHAP 6: ANALISIS DATA EKSPLORATIF PASCA-VALIDASI ===")

# 1. Membaca data yang SUDAH divalidasi manual
df_validated = pd.read_csv('data_mentah_untuk_validasi.csv')

# 2. Standarisasi nama kolom target menjadi 'intent'
df_validated.rename(columns={'Label_Validasi': 'intent'}, inplace=True)

# 3. [PENGAMANAN] Membersihkan ketidaksengajaan spasi/huruf besar saat ngetik
↳ di Excel
df_validated['intent'] = df_validated['intent'].astype(str).str.lower().str.
↳ strip()

print("Variasi label yang terdeteksi di sistem:")
print(df_validated['intent'].unique())
print("-" * 40)

# 4. Menghitung distribusi kelas aktual (Ground Truth)
print("--- Distribusi Kelas Aktual (Ground Truth) ---")
dist = df_validated['intent'].value_counts()
print(dist)

# 5. Visualisasi Ketimpangan
sns.set_theme(style="whitegrid")
plt.figure(figsize=(8, 5))
ax = sns.barplot(x=dist.index, y=dist.values, palette='viridis')
plt.title('Distribusi Kelas Pasca Validasi Manual (Ground Truth)', fontsize=14,
↳ fontweight='bold')
plt.xlabel('Intent (Niat)', fontsize=12)
```

```
plt.ylabel('Jumlah Pesan', fontsize=12)

for p in ax.patches:
    ax.annotate(f'{int(p.get_height())}',
                (p.get_x() + p.get_width() / 2., p.get_height()),
                ha='center', va='center', xytext=(0, 9), textcoords='offset_
↳points')
plt.show()
```

=== TAHAP 6: ANALISIS DATA EKSPLORATIF PASCA-VALIDASI ===

Variasi label yang terdeteksi di sistem:

['setuju' 'lainnya' 'batal']

--- Distribusi Kelas Aktual (Ground Truth) ---


intent

lainnya 1145

setuju 389

batal 34

Name: count, dtype: int64



0.7 7. Strategi Penyeimbangan Data Menggunakan AI (*Hybrid Balancing dengan LLM Groq*)

Tujuan Akademis: Menyembuhkan ketimpangan data agar model *Machine Learning* nantinya tidak bias. **Tindakan:** Menerapkan strategi *Hybrid Sampling* dengan target ekuilibrium **500 sampel per kelas**: 1. **Undersampling:** Memangkas data kelas lainnya secara acak dari 1145 menjadi 500 sampel. 2. **Generative Oversampling (AI):** Meminta LLM (Groq Llama-3) untuk memproduksi (*generate*) ratusan skenario percakapan baru dengan gaya bahasa Pontianak. Kelas setuju akan ditambah ~111 kalimat baru, dan kelas batal akan ditambah ~466 kalimat baru. 3. **Penyimpanan:** Menyimpan hasil ini menjadi *file* sementara agar bisa diinspeksi.

0.8 7.1 Penyeimbangan Data: Undersampling Kelas Mayoritas

Tujuan: Memangkas jumlah data pada kelas lainnya yang terlalu dominan (1145 baris) menjadi setara dengan batas ekuilibrium yang kita tentukan, yaitu 500 baris. Pemangkasan dilakukan secara acak (*random sampling*) agar tidak menghilangkan variasi natural dari data.

```
[21]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

print("=== TAHAP 7.1: UNDERSAMPLING KELAS MAYORITAS ===")

TARGET_SAMPLES = 500

# 1. Memisahkan data berdasarkan kelas masing-masing
df_lainnya = df_validated[df_validated['intent'] == 'lainnya'].copy()
df_setuju = df_validated[df_validated['intent'] == 'setuju'].copy()
df_batal = df_validated[df_validated['intent'] == 'batal'].copy()

# 2. Melakukan Undersampling pada kelas 'lainnya'
if len(df_lainnya) > TARGET_SAMPLES:
    df_lainnya = df_lainnya.sample(n=TARGET_SAMPLES, random_state=42)

# 3. Menggabungkan kembali data asli yang sudah dipangkas
df_hybrid = pd.concat([df_lainnya, df_setuju, df_batal], ignore_index=True)

# 4. Menambahkan penanda bahwa ini adalah data asli dari pelanggan
df_hybrid['source'] = 'real'

# 5. Menyeragamkan nama kolom agar rapi
if 'Teks Asli' in df_hybrid.columns:
    df_hybrid.rename(columns={'Teks Asli': 'text', 'Cleaned_Message': 'clean_text'}, inplace=True)
elif 'Message Body' in df_hybrid.columns:
    df_hybrid.rename(columns={'Message Body': 'text', 'Cleaned_Message': 'clean_text'}, inplace=True)
```

```

print(f" Undersampling selesai.")
print(f"- Jumlah kelas 'lainnya' sekarang : {len(df_lainnya)} baris.")
print(f"- Jumlah kelas 'setuju' (asli)      : {len(df_setuju)} baris.")
print(f"- Jumlah kelas 'batal' (asli)       : {len(df_batal)} baris.")

# =====
# VISUALISASI HASIL UNDERSAMPLING
# =====
print("\n--- Visualisasi Sementara (Pasca-Undersampling) ---")
dist_hybrid = df_hybrid['intent'].value_counts()
print(dist_hybrid)

sns.set_theme(style="whitegrid")
plt.figure(figsize=(8, 5))
ax = sns.barplot(x=dist_hybrid.index, y=dist_hybrid.values, palette='magma')
plt.title('Distribusi Kelas Pasca-Undersampling (Lainnya dipangkas)',
          ↪fontsize=14, fontweight='bold')
plt.xlabel('Intent (Niat)', fontsize=12)
plt.ylabel('Jumlah Pesan (Real)', fontsize=12)

for p in ax.patches:
    ax.annotate(f'{int(p.get_height())}',
                (p.get_x() + p.get_width() / 2., p.get_height()),
                ha='center', va='center', xytext=(0, 9), textcoords='offset_
                ↪points')
plt.show()

```

=== TAHAP 7.1: UNDERSAMPLING KELAS MAYORITAS ===

Undersampling selesai.

- Jumlah kelas 'lainnya' sekarang : 500 baris.
- Jumlah kelas 'setuju' (asli) : 389 baris.
- Jumlah kelas 'batal' (asli) : 34 baris.

--- Visualisasi Sementara (Pasca-Undersampling) ---

```

intent
lainnya    500
setuju     389
batal       34
Name: count, dtype: int64

```

