

Data_Preprocessing

August 18, 2026

1 Pra-Pemrosesan dan Pelabelan Niat Pelanggan Service Komputer

```
[86]: import pandas as pd
import numpy as np
import re
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Mengatur palet warna monokrom untuk estetika pencetakan akademis
sns.set_palette(['#333333', '#777777', '#cccccc'])

df_mentah = pd.read_csv('data/master_chat_wa.csv')
print("=== METADATA DATA UTAMA ===")
df_mentah.info()
print("\n=== SAMPEL DATA UTAMA ===")
display(df_mentah.head(3))
```

```
=== METADATA DATA UTAMA ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3502 entries, 0 to 3501
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Country                3502 non-null  object
1   Phone Number           3502 non-null  int64
2   Formatted Name         3502 non-null  object
3   Display Name           3418 non-null  object
4   Message Time           3502 non-null  object
5   Message Type           3502 non-null  object
6   Message Body           3447 non-null  object
7   Message Id             3502 non-null  object
dtypes: int64(1), object(7)
memory usage: 219.0+ KB

=== SAMPEL DATA UTAMA ===
```

	Country	Phone Number	Formatted Name	Display Name	\
0	Indonesia	6285752887496		Anda	anugerahcomputer4
1	Indonesia	6285752887496		Anda	anugerahcomputer4
2	Indonesia	6281156701235	+62 811-5670-1235		NaN

	Message Time	Message Type	Message Body	\
0	2026-04-27 12:10:50	chat	IMAGE	
1	2026-04-27 12:10:55	chat	Anugerah komputer	
2	2026-04-27 16:13:57	chat	Oke bg	

	Message Id
0	true_211622366855206@lid_AC2292D9378555369E125...
1	true_211622366855206@lid_ACEC981E86F9304411889...
2	false_211622366855206@lid_ACCC7B568284EA7BDECA...

1.1 Ekstraksi Fitur Dasar

Memecah atribut Message Id untuk mengidentifikasi siapa pengirim pesan (Admin atau Pelanggan) dan ID Obrolan (Chat_ID) untuk merekonstruksi riwayat percakapan.

```
[87]: # 1. Konversi Teks menjadi Objek Waktu agar dapat dihitung secara matematis
df_mentah['Message Time'] = pd.to_datetime(df_mentah['Message Time'],
      ↪errors='coerce')

# 2. Menghapus baris anomali yang waktu pesannya gagal dikonversi
df_mentah = df_mentah.dropna(subset=['Message Time']).copy()

# 3. Ekstraksi Fitur 1: is_admin (True jika pesan dari admin, False jika dari
      ↪pelanggan)
df_mentah['is_admin'] = df_mentah['Message Id'].astype(str).str.
      ↪startswith('true_')

# 4. Ekstraksi Fitur 2: Chat_ID (Mengambil string di antara 'true_/'/'false_'
      ↪dan '@')
df_mentah['Chat_ID'] = df_mentah['Message Id'].astype(str).apply(lambda x: x.
      ↪split('_')[1].split('@')[0] if len(x.split('_')) > 1 else 'unknown')

print("=== HASIL EKSTRAKSI FITUR DASAR ===")
display(df_mentah[['Message Time', 'is_admin', 'Chat_ID', 'Message Body']].
      ↪head())
```

=== HASIL EKSTRAKSI FITUR DASAR ===

	Message Time	is_admin	Chat_ID	\
0	2026-04-27 12:10:50	True	211622366855206	
1	2026-04-27 12:10:55	True	211622366855206	
2	2026-04-27 16:13:57	False	211622366855206	
3	2026-04-29 10:17:27	False	211622366855206	
4	2026-04-29 10:18:06	True	211622366855206	

	Message Body
0	IMAGE
1	Anugerah komputer
2	Oke bg
3	Bg berapa kemarin harganya ya
4	Nnti tnya y bg blom dtg bos nya

1.2 Cek Keterlambatan Waktu Respons

Menghitung selisih waktu antara pesan pelanggan masuk dan balasan dari admin dalam satu obrolan untuk memvalidasi masalah operasional toko.

```
[88]: # MENGAMBIL OBROLAN (CHAT ID)
print("=== Melihat obrolan ===")
contoh_kamar = df_mentah['Chat_ID'].dropna().unique()[145]
bukti_percakapan = df_mentah[df_mentah['Chat_ID'] == contoh_kamar].
    ↳sort_values('Message Time')

for idx, row in bukti_percakapan.iterrows():
    waktu = row['Message Time'].strftime('%Y-%m-%d %H:%M:%S')
    pengirim = "ADMIN" if row['is_admin'] else "PELANGGAN"
    pesan = row['Message Body']
    print(f"[{waktu}] {pengirim}: {pesan}")
```

```
=== Melihat obrolan ===
[2025-10-20 14:11:31] ADMIN: Selamat pagi bang. Laptop Advan nya udh kami cek
bang, mic internal nya gak berfungsi kak
[2025-10-20 15:10:31] ADMIN: Untuk perbaikannya kena Rp200.000 bang
[2025-10-20 15:31:31] PELANGGAN: Bisa kurang gak bang?
[2025-10-20 16:15:31] ADMIN: Udah pas segitu bang, itu udh termasuk part + jasa
[2025-10-20 16:54:31] PELANGGAN: Nanti aja perbaikannya bang
[2025-10-20 17:01:31] ADMIN: Ok bang dimengerti
```

```
[89]: # Mengurutkan percakapan berdasarkan ruang obrolan dan waktu
df_mentah = df_mentah.sort_values(by=['Chat_ID', 'Message Time']).
    ↳reset_index(drop=True)

response_times = []
unreplied = 0
total_inquiries = 0

# Iterasi untuk mensimulasikan penghitungan waktu tunggu
for chat_id, group in df_mentah.groupby('Chat_ID'):
    group = group.sort_values('Message Time').reset_index(drop=True)
    waiting = False
    inq_time = None
```

```

for _, row in group.iterrows():
    if not row['is_admin']:
        if not waiting:
            waiting = True
            inq_time = row['Message Time']
            total_inquiries += 1
        else:
            if waiting:
                delay_minutes = (row['Message Time'] - inq_time).
↳total_seconds() / 60.0
                response_times.append(delay_minutes)
                waiting = False

    if waiting:
        unreplied += 1

print(f"Total Sesi Inisiasi Pelanggan: {total_inquiries}")
print(f"Sesi Diabaikan Admin: {unreplied}")
print(f"Rata-Rata Tunggu (Bagi yang Dibalas): {np.mean(response_times):.2f}↳
↳Menit")

```

Total Sesi Inisiasi Pelanggan: 1171
 Sesi Diabaikan Admin: 198
 Rata-Rata Tunggu (Bagi yang Dibalas): 631.79 Menit

```


[90]: # Klasifikasi keterlambatan
lambat = sum(1 for x in response_times if x > 120)
normal = total_inquiries - unreplied - lambat

labels = ['Respons Ideal (< 2 Jam)', 'Tanggapan Lambat (> 2 Jam)', 'Diabaikan↳
↳Sepenuhnya']
sizes = [normal, lambat, unreplied]
colors = ['#cccccc', '#888888', '#333333']
explode = (0, 0.1, 0.1)

plt.figure(figsize=(8, 6))
plt.pie(sizes, explode=explode, labels=labels, colors=colors, autopct='%1.1f%%',
        shadow=True, startangle=140, textprops={'fontsize': 11, 'color':↳
↳'black'})
plt.title(f'Distribusi Balasan Pesan (Total {total_inquiries} Sesi)',↳
↳fontsize=13, fontweight='bold', pad=20)
plt.axis('equal')
plt.show()

```

Distribusi Balasan Pesan (Total 1171 Sesi)



1.3 Pembersihan (*Noise Reduction*) & Normalisasi Dasar

Membersihkan lampiran gambar otomatis, pesan kosong, dan melakukan *Case Folding* (huruf kecil).

```
[91]: # 1. Menghapus pesan otomatis WA berupa lampiran gambar IMAGE
df_bersih = df_mentah[~df_mentah['Message Body'].astype(str).str.contains(r' .*?
↪ ', regex=True)].copy()

# 2. Menghapus baris yang teksnya kosong atau NaN
df_bersih = df_bersih.dropna(subset=['Message Body']).copy()
df_bersih = df_bersih[df_bersih['Message Body'].astype(str).str.strip() != '']

# 3. Case Folding (Ubah ke huruf kecil semua)
df_bersih['text_lower'] = df_bersih['Message Body'].astype(str).str.lower()

print(f"Sisa Data Setelah Noise Reduction: {len(df_bersih)} baris")
```

Sisa Data Setelah Noise Reduction: 3078 baris

1.4 Identifikasi Aktor & Standarisasi Teks

Mengekstrak pesan khusus dari pelanggan saja, dan mendefinisikan fungsi standarisasi tanda baca (`text_normalization`) yang akan digunakan sepanjang riset.

```
[92]: # Menyaring tabel HANYA untuk pesan pelanggan
df_pelanggan = df_bersih[df_bersih['is_admin'] == False].copy()

# Definisi Fungsi Standarisasi Akademis
def text_normalization(text):
    if not isinstance(text, str): return ""
    text = text.lower() # Huruf kecil
    text = re.sub(r'http\S+|www\S+|https\S+', '', text, flags=re.MULTILINE) # Hapus Tautan
    text = re.sub(r'[\a-z\s]', '', text) # Hapus tanda baca
    text = re.sub(r'\s+', ' ', text).strip() # Rapihan spasi berlebih
    return text

# Terapkan standarisasi pada teks pelanggan
df_pelanggan['clean_text'] = df_pelanggan['text_lower'].
    .apply(text_normalization)

print(f"Total Pesan Murni Pelanggan: {len(df_pelanggan)} baris")
print("\n=== 5 PESAN TERBANYAK (MURNI PELANGGAN) ===")
print(df_pelanggan['clean_text'].value_counts().head(5))
```

Total Pesan Murni Pelanggan: 1581 baris

```
=== 5 PESAN TERBANYAK (MURNI PELANGGAN) ===
clean_text
ok                29
oke bang          29
oke bg            14
                  13
ok bg             11
Name: count, dtype: int64
```

1.5 Pra-Pelabelan

Implementasi algoritma pencocokan kata kunci berdasarkan observasi *Ground Truth* awal untuk menyuntikkan label otomatis (setuju, batal, lainnya).

```
[93]: def rule_based_labeler(text):
    # Kata kunci khas dialek dan kebiasaan membalas
    kunci_batal = ['batal', 'tak usah', 'btl', 'cancel', 'kemahalan', 'mahal', 'ndak jadi', 'skip', 'ambil aja', 'ambil yak', 'nanti dolok']
    kunci_setuju = ['lanjut', 'setuju', 'sikat', 'oke', 'boleh', 'iyak', 'ganti', 'kerjakan', 'gas', 'baik', 'ok', 'iya', 'okey']
```

```

    if any(word in text for word in kunci_batal):
        return 'batal'
    elif any(word in text for word in kunci_setuju):
        return 'setuju'
    else:
        return 'lainnya'


df_pelanggan['intent'] = df_pelanggan['clean_text'].apply(rule_based_labeler)

distribusi_awal = df_pelanggan['intent'].value_counts()
print("=== HASIL PRA-PELABELAN OTOMATIS ===")
print(distribusi_awal)

# Visualisasi Ketimpangan Kelas
plt.figure(figsize=(7, 4))
bars = plt.bar(distribusi_awal.index, distribusi_awal.values, color='#888888',
               ↪edgecolor='black', width=0.5)
plt.title(' Distribusi Kelas pada Master Data WA ', fontsize=12,
         ↪fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center',
            ↪va='bottom', fontweight='bold')
plt.show()

=== HASIL PRA-PELABELAN OTOMATIS ===
intent
lainnya      839
setuju       702
batal         40
Name: count, dtype: int64

```



```
[94]: # Mengekspor hasil pra-pelabelan mesin untuk divalidasi
df_pelanggan.to_csv('data/hasil_prapelabelan_mesin.csv', index=False)
print("File CSV berhasil diekspor! ...")
```

File CSV berhasil diekspor! ...

```
[95]: # 1. Memuat data Master Chat yang sudah divalidasi
df_validasi = pd.read_csv('data/master_chat_tervalidasi.csv')

print("=== cuplikan data udah di validasi ===")
display(df_validasi[['clean_text', 'intent']].sample(5, random_state=42))

# 2. Menghitung distribusi niat hasil validasi
distribusi_validasi = df_validasi['intent'].value_counts()
print("\n=== DISTRIBUSI LABEL VALIDASI ===")
print(distribusi_validasi)

# 3. Visualisasi Komparasi
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

# Tebakan Mesin
axes[0].bar(distribusi_awal.index, distribusi_awal.values, color='#cccccc',
            edgecolor='black', width=0.5)
axes[0].set_title('Tebakan Awal Mesin', fontsize=11, fontweight='bold')
```

```

axes[0].set_ylabel('Volume Data')
for bar in axes[0].patches:
    axes[0].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 5, int(bar.
    ↪get_height()), ha='center', va='bottom', fontweight='bold')

# Validasi Final
axes[1].bar(distribusi_validasi.index, distribusi_validasi.values,
    ↪color='#777777', edgecolor='black', width=0.5)
axes[1].set_title('Validasi Final', fontsize=11, fontweight='bold')
for bar in axes[1].patches:
    axes[1].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 5, int(bar.
    ↪get_height()), ha='center', va='bottom', fontweight='bold')

plt.suptitle('Akurasi Tebakan Mesin vs Koreksi Manusia', fontsize=14,
    ↪fontweight='bold', y=1.05)
plt.tight_layout()
plt.show()

```

=== cuplikan data udah di validasi ===


	clean_text	intent
1124	besok buka jamber	lainnya
813	tak bisa kurang lg k	setuju
1175	diskon dikit boleh bg	lainnya
534	baik bang	setuju
514	buka sampe jam berapa bg	lainnya

=== DISTRIBUSI LABEL VALIDASI ===

```

intent
lainnya    878
setuju     661
batal      42
Name: count, dtype: int64

```



Data baru dari ekstraksi wa (`data_baru_dari_wa_clean.csv`) digabungkan dengan `df_pelanggan` di gabung kan chat master yang udah di validasi

```
[96]: # 1. Memuat data
df_wa_suplemen = pd.read_csv('data/data_baru_dari_wa_clean.csv')

# 2. Standarisasi Teks Data
df_wa_suplemen['clean_text'] = df_wa_suplemen['text'].apply(text_normalization)
df_wa_suplemen['intent'] = df_wa_suplemen['intent'].astype(str).str.lower().str.
    ↳strip()

# 3. MENGAMBIL 4 KOLOM EMAS & MENYUNTIKKAN SUMBER (SOURCE)
# Untuk master chat (kita ubah nama 'Message Body' menjadi 'text' agar seragam)
df_wa_utama = df_validasi[['Message Body', 'clean_text', 'intent']].copy()
df_wa_utama = df_wa_utama.rename(columns={'Message Body': 'text'})
df_wa_utama['source'] = 'master_chat'

# Untuk data suplemen
df_wa_suplemen_bersih = df_wa_suplemen[['text', 'clean_text', 'intent']].copy()
df_wa_suplemen_bersih['source'] = 'suplemen_wa'

# 4. Peleburan & Hapus Duplikasi
df_wa_final = pd.concat([df_wa_utama, df_wa_suplemen_bersih], ignore_index=True)
df_wa_final = df_wa_final.drop_duplicates(subset=['clean_text', 'intent'])
df_wa_final = df_wa_final[df_wa_final['clean_text'] != ''] # Hapus string kosong


# 5. EKSPOR KE CSV FINAL WA
df_wa_final.to_csv('data/dataset_wa_final.csv', index=False)
print("=== EKSPOR BERHASIL: dataset_wa_final.csv ===")

distribusi_wa_final = df_wa_final['intent'].value_counts()
print(f"Total Baris Ekosistem WA Tervalidasi: {len(df_wa_final)} Baris\n")

# Visualisasi Ekosistem WA
plt.figure(figsize=(8, 5))
bars = plt.bar(distribusi_wa_final.index, distribusi_wa_final.values,
    ↳color='#777777', edgecolor='black', linewidth=1.5, width=0.5)
plt.title('Distribusi Niat pada Ekosistem WhatsApp Tervalidasi', fontsize=13,
    ↳fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center',
    ↳va='bottom', fontweight='bold')
```

```
plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()
```

=== EKSPOR BERHASIL: dataset_wa_final.csv ===
 Total Baris Ekosistem WA Tervalidasi: 1388 Baris



1.6 Data Primer

Data hasil penyebaran kuesioner memiliki struktur *Wide-Format* (horizontal) di mana satu responden mengisi enam skenario jawaban. Agar dapat dilatih oleh model *Machine Learning*, data ini harus dikonversi menjadi *Long-Format* (vertikal) melalui proses *Data Melting*. Selanjutnya, data ini akan distandarisasi menggunakan fungsi `text_normalization` yang sama dengan ekosistem WhatsApp demi menjaga konsistensi matriks fitur teks.

```
[97]: # 1. Memuat file raw kuesioner
path_kuesioner = 'data/
↳Pengumpulan_Data_Linguistik_Interaksi_Layanan_Pelanggan_untuk_Pelatihan_Model_Natural_Langu
↳csv'
df_raw_kuesioner = pd.read_csv(path_kuesioner)

print("=== CUPLIKAN DATA KUESIONER===")
display(df_raw_kuesioner.head(3))
```

=== CUPLIKAN DATA KUESIONER===

	Timestamp	Rentang Usia	\
0	18/08/2026 08:12:14	18 - 25 Tahun	
1	18/08/2026 08:17:39	18 - 25 Tahun	
2	18/08/2026 08:23:51	25 - 35 Tahun	

Tingkat pemahaman dan penggunaan dialek Melayu Pontianak dalam komunikasi

pesan teks \

0	Aktif (Sering menggunakan)
1	Aktif (Sering menggunakan)
2	Aktif (Sering menggunakan)

1. Persetujuan biaya \

0	Oke kak lanjutkan jak
1	Siap kak, setuju dengan biayanya
2	Boleh bang, lanjut servis

2. Persetujuan dialek/instruksi \

0	Aok kak gas jak, mun bise dikerje hari tok bah
1	Aok min, teruskan jak install Windowsnye hari ...
2	Boleh bah bang, pasang jak SSD tu biar ndak le...

3. Penolakan & ambil unit \

0	Untuk sementara saya ambil laptopnya dulu kak
1	Saya ambil kembali barangnya saja
2	Ndak usah diteruskan, nanti saya ambil

4. Pembatalan/penolakan dialek \

0	Ndak jadi dulu bang, duetnye belum cukup lok
1	Kayaknye ditunda dulu lah kak, duit saye lagi ...
2	Maaf bang, untuk sekarang belum sanggup di biyai

5. Negosiasi harga \

0	Bise kurang sikit ndak bang, 600 ribu gimane?
1	Harga SSDnye masih bise turun lagi kah kak?
2	Kalau 650 ribu bisa jak ndak bang?

6. Pertanyaan durasi/info

0	Install ulangnye kira-kira siap jam berape kak?
1	Mun ganti SSD sekalian install Windows, lame n...
2	Kapan kira-kira laptop habis dikerjakan bang?

```
[98]: # Kita ambil HANYA nama-nama kolom yang berisi teks jawaban (indeks ke-3 sampai
      ↪batas ke-9)
      kolom_teks = df_raw_kuesioner.columns[3:9]

      print("=== KOLOM PERTANYAAN YANG AKAN DILABELI ===")
      for i, col in enumerate(kolom_teks):
```

```
print(f"{i+1}. {col}")
```

=== KOLOM PERTANYAAN YANG AKAN DILABELI ===

1. 1. Persetujuan biaya
2. 2. Persetujuan dialek/instruksi
3. 3. Penolakan & ambil unit
4. 4. Pembatalan/penolakan dialek
5. 5. Negosiasi harga
6. 6. Pertanyaan durasi/info

```
[99]: # Fungsi 'melt' meruntuhkan 6 kolom menyamping menjadi format vertikal
df_kuesioner_melted = df_raw_kuesioner.melt(
    id_vars=[],
    value_vars=kolom_teks,
    var_name='pertanyaan',
    value_name='text'
)

print(f"Jumlah baris sekarang: {len(df_kuesioner_melted)}")
display(df_kuesioner_melted.head(5))
```

Jumlah baris sekarang: 618

	pertanyaan	text
0	1. Persetujuan biaya	Oke kak lanjutkan jak
1	1. Persetujuan biaya	Siap kak, setuju dengan biayanya
2	1. Persetujuan biaya	Boleh bang, lanjut servis
3	1. Persetujuan biaya	Oke kak saya setuju
4	1. Persetujuan biaya	Gas bang, boleh lanjut

```
[100]: # Membuat kamus pemetaan manual berdasarkan urutan 6 kolom pertanyaan tadi
mapping_intent = {
    kolom_teks[0]: 'setuju',
    kolom_teks[1]: 'setuju',
    kolom_teks[2]: 'batal',
    kolom_teks[3]: 'batal',
    # kolom_teks[4]: 'lainnya',
    # kolom_teks[5]: 'lainnya'
}

# 1. Suntik label dengan cara menerjemahkan kolom 'pertanyaan'
df_kuesioner_melted['intent'] = df_kuesioner_melted['pertanyaan'].
    ↪map(mapping_intent)

# 2. Membersihkan data yang kosong (jika ada responden yang tidak mengisi)
df_kuesioner_melted = df_kuesioner_melted.dropna(subset=['text']).copy()

# 3. Terapkan Standarisasi (rumus andalan kita)
```

```

df_kuesioner_melted['clean_text'] = df_kuesioner_melted['text'].
    ↪apply(text_normalization)

# 4. Suntik sumber data
df_kuesioner_melted['source'] = 'kuesioner'

# 5. Bungkus dan ambil 4 Kolom Emas
df_kuesioner_final = df_kuesioner_melted[['text', 'clean_text', 'intent',
    ↪'source']].copy()

print("=== HASIL AKHIR EKSTRAKSI DATA KUESIONER ===")
display(df_kuesioner_final.sample(5, random_state=42))

```

=== HASIL AKHIR EKSTRAKSI DATA KUESIONER ===

	text \			
49	Oke siap			
582	Windows corrupt macam ni biasanya perlu berapa...			
82	Siap bang, lanjutkan			
305	Saya ambil barang dulu bang			
109	Aok bang, betolkan jak, saye perlu pakai cepat			
	clean_text	intent	source	
49	oke siap	setuju	kuesioner	
582	windows corrupt macam ni biasanya perlu berapa...	NaN	kuesioner	
82	siap bang lanjutkan	setuju	kuesioner	
305	saya ambil barang dulu bang	batal	kuesioner	
109	aok bang betolkan jak saye perlu pakai cepat	setuju	kuesioner	

```

[101]: # Menghitung distribusi niat pada data kuesioner
distribusi_kuesioner = df_kuesioner_final['intent'].value_counts()

print("=== DISTRIBUSI LABEL KUESIONER ===")
print(distribusi_kuesioner)

# Membuat Bar Chart Monokrom
plt.figure(figsize=(7, 5))
bars = plt.bar(distribusi_kuesioner.index, distribusi_kuesioner.values,
    ↪color='#888888', edgecolor='black', width=0.5)

plt.title('Visualisasi 4: Distribusi Niat pada Data Kuesioner (Sangat
    ↪Seimbang)', fontsize=12, fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat', fontsize=11)
plt.ylabel('Volume Data', fontsize=11)
plt.ylim(0, max(distribusi_kuesioner.values) + 30)

for bar in bars:
    yval = bar.get_height()

```

```
plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center', va='bottom', fontweight='bold')
```

```
plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()
```

=== DISTRIBUSI LABEL KUESIONER ===


intent

setuju 206

batal 206

Name: count, dtype: int64

Visualisasi 4: Distribusi Niat pada Data Kuesioner (Sangat Seimbang)



1.7 Ekosistem WA dan Kuesioner (Dataset Siap Latih)

menggabungkan dataset historis WhatsApp yang mencerminkan interaksi natural, dengan dataset Kuesioner yang memperkaya ragam dialek dan mengangkat volume kelas minoritas. Dataset gabungan ini diekspor menjadi matriks akhir yang siap dilatih oleh algoritma NLP.

```
[102]: # 1. Memuat kembali data WA Final
df_wa_final = pd.read_csv('data/dataset_wa_final.csv')

# 2. Penggabungan (Concatenation) WA dan Kuesioner
```

```

df_siap_latih = pd.concat([df_wa_final, df_kuesioner_final], ignore_index=True)

# 3. Menghapus duplikasi silang
df_siap_latih = df_siap_latih.drop_duplicates(subset=['clean_text', 'intent']).
    copy()

# 4. EKSPOR KE CSV FINAL
df_siap_latih.to_csv('data/dataset_siap_latih_final.csv', index=False)
print("=== EKSPOR BERHASIL: dataset_siap_latih_final.csv ===")

# 5. Visualisasi Distribusi Final (Untuk Menentukan Tindakan di Tahap Training)
distribusi_siap_latih = df_siap_latih['intent'].value_counts()
print("\n=== DISTRIBUSI LABEL FINAL===")
print(distribusi_siap_latih)

plt.figure(figsize=(8, 5))
bars = plt.bar(distribusi_siap_latih.index, distribusi_siap_latih.values,
    color='#555555', edgecolor='black', linewidth=1.5, width=0.5)

plt.title('Distribusi Final Dataset Siap Latih', fontsize=13,
    fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
plt.ylim(0, max(distribusi_siap_latih.values) + 150) # Ruang ekstra

for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 10, int(yval),
    ha='center', va='bottom', fontweight='bold')

plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()

```

```

=== EKSPOR BERHASIL: dataset_siap_latih_final.csv ===

```

```

=== DISTRIBUSI LABEL FINAL===

```

```

intent
lainnya      820
setuju       697
batal        249
Name: count, dtype: int64

```

