

Data_Preprocessing_Rapi

August 18, 2026

1 Analisis Skripsi: Pra-Pemrosesan dan Pelabelan Niat Pelanggan Service Komputer

Notebook ini merupakan pipeline absolut yang telah distandarisasi secara metodologis dari Bab I hingga Konsolidasi WA Final.

1.1 BAB I: Inisialisasi Lingkungan & Memuat Data Utama

Memuat pustaka yang dibutuhkan dan mengimpor data utama (*Master Chat WhatsApp*).

```
[26]: import pandas as pd
import numpy as np
import re
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Mengatur palet warna monokrom untuk estetika pencetakan akademis
sns.set_palette(['#333333', '#777777', '#cccccc'])

df_mentah = pd.read_csv('data/master_chat_wa.csv')
print("=== METADATA DATA UTAMA ===")
df_mentah.info()
print("\n=== SAMPEL DATA UTAMA ===")
display(df_mentah.head(3))
```

```
=== METADATA DATA UTAMA ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3502 entries, 0 to 3501
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Country                3502 non-null   object
1   Phone Number           3502 non-null   int64
2   Formatted Name         3502 non-null   object
3   Display Name           3418 non-null   object
4   Message Time           3502 non-null   object
5   Message Type           3502 non-null   object
```

```

6   Message Body      3447 non-null   object
7   Message Id        3502 non-null   object
dtypes: int64(1), object(7)
memory usage: 219.0+ KB

```

=== SAMPEL DATA UTAMA ===

	Country	Phone Number	Formatted Name	Display Name \
0	Indonesia	6285752887496	Anda	anugerahcomputer4
1	Indonesia	6285752887496	Anda	anugerahcomputer4
2	Indonesia	6281156701235	+62 811-5670-1235	NaN

	Message Time	Message Type	Message Body \
0	2026-04-27 12:10:50	chat	IMAGE
1	2026-04-27 12:10:55	chat	Anugerah komputer
2	2026-04-27 16:13:57	chat	Oke bg

	Message Id
0	true_211622366855206@lid_AC2292D9378555369E125...
1	true_211622366855206@lid_ACEC981E86F9304411889...
2	false_211622366855206@lid_ACCC7B568284EA7BDECA...

1.2 BAB II: Ekstraksi Fitur Dasar

Memecah atribut Message Id untuk mengidentifikasi siapa pengirim pesan (Admin atau Pelanggan) dan ID Kamar Obrolan (Chat_ID) untuk merekonstruksi riwayat percakapan.

```

[27]: # 1. Konversi Teks menjadi Objek Waktu agar dapat dihitung secara matematis
df_mentah['Message Time'] = pd.to_datetime(df_mentah['Message Time'],
      ↪errors='coerce')

# 2. Menghapus baris anomali yang waktu pesannya gagal dikonversi
df_mentah = df_mentah.dropna(subset=['Message Time']).copy()

# 3. Ekstraksi Fitur 1: is_admin (True jika pesan dari admin, False jika dari
      ↪pelanggan)
df_mentah['is_admin'] = df_mentah['Message Id'].astype(str).str.
      ↪startswith('true_')

# 4. Ekstraksi Fitur 2: Chat_ID (Mengambil string di antara 'true_ '/'false_'
      ↪dan '@')
df_mentah['Chat_ID'] = df_mentah['Message Id'].astype(str).apply(lambda x: x.
      ↪split('_')[1].split('@')[0] if len(x.split('_')) > 1 else 'unknown')

print("=== HASIL EKSTRAKSI FITUR DASAR ===")
display(df_mentah[['Message Time', 'is_admin', 'Chat_ID', 'Message Body']].
      ↪head())

```

=== HASIL EKSTRAKSI FITUR DASAR ===

	Message Time	is_admin	Chat_ID \
0	2026-04-27 12:10:50	True	211622366855206
1	2026-04-27 12:10:55	True	211622366855206
2	2026-04-27 16:13:57	False	211622366855206
3	2026-04-29 10:17:27	False	211622366855206
4	2026-04-29 10:18:06	True	211622366855206

	Message Body
0	IMAGE
1	Anugerah komputer
2	Oke bg
3	Bg berapa kemarin harganya ya
4	Nnti tnya y bg blom dtg bos nya

1.3 BAB III: Pembuktian Masalah Keterlambatan Waktu Respons

Menghitung selisih waktu antara pesan pelanggan masuk dan balasan dari admin dalam satu kamar obrolan untuk memvalidasi masalah operasional toko.

```
[28]: # MENGAMBIL BUKTI NYATA DARI 1 KAMAR OBROLAN (CHAT ID)
print("=== BUKTI REKAMAN KRONOLOGIS 1 KAMAR OBROLAN ===")
contoh_kamar = df_mentah['Chat_ID'].dropna().unique()[2] # Mengambil kamar_
↳urutan ke-3
bukti_percakapan = df_mentah[df_mentah['Chat_ID'] == contoh_kamar].
↳sort_values('Message Time')

for idx, row in bukti_percakapan.iterrows():
    waktu = row['Message Time'].strftime('%Y-%m-%d %H:%M:%S')
    pengirim = "ADMIN" if row['is_admin'] else "PELANGGAN"
    pesan = row['Message Body']
    print(f"[{waktu}] {pengirim}: {pesan}")
```

```
=== BUKTI REKAMAN KRONOLOGIS 1 KAMAR OBROLAN ===
[2026-03-17 09:25:19] PELANGGAN: misa bg sya kemarin servis laptop ditempat abg
atas nama maya laptop ya nd mau hidup lgi
[2026-03-17 09:25:30] PELANGGAN: IMAGE
[2026-03-17 09:26:56] PELANGGAN: abg buka nd yah hari ini saya antar laptop lgi
[2026-03-17 09:48:58] ADMIN: Buka kak tapi sampai sore. Soalnya toko mau tutup
pulang kampung. Bisa d bawa ke toko kak laptopnya
[2026-03-17 09:49:16] PELANGGAN: oke nnti saya bawa
[2026-03-17 10:01:19] ADMIN: Oke kak
[2026-04-01 13:31:07] PELANGGAN: bg mau tanya laptop nya udh betul belum
[2026-04-01 13:48:50] ADMIN: Blm kak. Kami Senin tadi baru buka. Listrik kami
masih bermasalah. Nanti kalau udah kami konfirmasi ya kak
[2026-04-01 13:49:19] PELANGGAN: oke bg
[2026-04-02 13:10:48] ADMIN: Kak laptopnya udah
[2026-04-02 13:11:17] ADMIN: IMAGE
[2026-04-02 13:11:40] PELANGGAN: besok sya ambil yah bg
```

```

[2026-04-02 13:11:46] ADMIN: Oke kak
[2026-04-02 13:12:43] PELANGGAN: bg ad biaya tambahan gk
[2026-04-02 13:15:43] ADMIN: Gak ada kak
[2026-04-02 13:15:57] PELANGGAN: oke bg
[2026-04-02 13:16:03] ADMIN: Oke kak
[2026-04-03 10:24:37] PELANGGAN: bg besok yk sye ambil nd sempat hri ni
[2026-04-03 11:25:34] ADMIN: Ok

```

```

[29]: # Mengurutkan percakapan berdasarkan ruang obrolan dan waktu
df_mentah = df_mentah.sort_values(by=['Chat_ID', 'Message Time']).
↳reset_index(drop=True)

response_times = []
unreplied = 0
total_inquiries = 0

# Iterasi untuk mensimulasikan penghitungan waktu tunggu (Simulasi Sederhana)
for chat_id, group in df_mentah.groupby('Chat_ID'):
    group = group.sort_values('Message Time').reset_index(drop=True)
    waiting = False
    inq_time = None

    for _, row in group.iterrows():
        if not row['is_admin']:
            if not waiting:
                waiting = True
                inq_time = row['Message Time']
                total_inquiries += 1
            else:
                if waiting:
                    delay_minutes = (row['Message Time'] - inq_time).
↳total_seconds() / 60.0
                    response_times.append(delay_minutes)
                    waiting = False

                if waiting:
                    unreplied += 1

print("=== KESIMPULAN FAKTUAL KINERJA PELAYANAN ===")
print(f"Total Sesi Inisiasi Pelanggan: {total_inquiries}")
print(f"Sesi Diabaikan Admin: {unreplied}")
print(f"Rata-Rata Tunggu (Bagi yang Dibalas): {np.mean(response_times):.2f}↳
↳Menit")

```

```

=== KESIMPULAN FAKTUAL KINERJA PELAYANAN ===
Total Sesi Inisiasi Pelanggan: 1171
Sesi Diabaikan Admin: 198
Rata-Rata Tunggu (Bagi yang Dibalas): 631.79 Menit


```

```
[30]: # Klasifikasi ambang batas keterlambatan ekstrem (> 4 Jam / 240 Menit)
lambat = sum(1 for x in response_times if x > 240)
normal = total_inquiries - unreplied - lambat

labels = ['Respons Ideal (< 4 Jam)', 'Tanggapan Lambat (> 4 Jam)', 'Diabaikan_
↳Sepenuhnya']
sizes = [normal, lambat, unreplied]
colors = ['#cccccc', '#888888', '#333333']
explode = (0, 0.1, 0.1)

plt.figure(figsize=(8, 6))
plt.pie(sizes, explode=explode, labels=labels, colors=colors, autopct='%1.1f%%',
        shadow=True, startangle=140, textprops={'fontsize': 11, 'color': '
↳black'})
plt.title(f'Visualisasi 1: Distribusi Kinerja Pelayanan Admin (Total_
↳{total_inquiries} Sesi)', fontsize=13, fontweight='bold', pad=20)
plt.axis('equal')
plt.show()
```

Visualisasi 1: Distribusi Kinerja Pelayanan Admin (Total 1171 Sesi)



1.4 BAB IV: Pembersihan Derau (*Noise Reduction*) & Normalisasi Dasar

Membersihkan lampiran gambar otomatis, pesan kosong, dan melakukan *Case Folding* (huruf kecil).

```
[31]: # 1. Menghapus pesan otomatis WA berupa lampiran gambar IMAGE
df_bersih = df_mentah[~df_mentah['Message Body'].astype(str).str.contains(r' .*?
↪ ', regex=True)].copy()

# 2. Menghapus baris yang teksnya kosong atau NaN
df_bersih = df_bersih.dropna(subset=['Message Body']).copy()
df_bersih = df_bersih[df_bersih['Message Body'].astype(str).str.strip() != '']

# 3. Case Folding (Ubah ke huruf kecil semua)
df_bersih['text_lower'] = df_bersih['Message Body'].astype(str).str.lower()

print(f"Sisa Data Setelah Noise Reduction: {len(df_bersih)} baris")
```

Sisa Data Setelah Noise Reduction: 3078 baris

1.5 BAB V: Identifikasi Aktor & Standarisasi Teks

Mengekstrak pesan khusus dari pelanggan saja, dan mendefinisikan fungsi standarisasi tanda baca (*text_normalization*) yang akan digunakan sepanjang riset.

```
[32]: # Menyaring tabel HANYA untuk pesan pelanggan
df_pelanggan = df_bersih[df_bersih['is_admin'] == False].copy()

# Definisi Fungsi Standarisasi Akademis
def text_normalization(text):
    if not isinstance(text, str): return ""
    text = text.lower() # Huruf kecil
    text = re.sub(r'http\S+|www\S+|https\S+', '', text, flags=re.MULTILINE) #_
↪ Hapus Tautan
    text = re.sub(r'[^a-z\s]', '', text) # Hapus tanda baca
    text = re.sub(r'\s+', ' ', text).strip() # Rapihan spasi berlebih
    return text

# Terapkan standarisasi pada teks pelanggan
df_pelanggan['clean_text'] = df_pelanggan['text_lower'].
↪ apply(text_normalization)

print(f"Total Pesan Murni Pelanggan: {len(df_pelanggan)} baris")
print("\n=== 5 PESAN TERBANYAK (MURNI PELANGGAN) ===")
print(df_pelanggan['clean_text'].value_counts().head(5))
```

Total Pesan Murni Pelanggan: 1581 baris

```
=== 5 PESAN TERBANYAK (MURNI PELANGGAN) ===
clean_text
```

```

ok                29
oke bang          29
oke bg            14
                  13
ok bg             11
Name: count, dtype: int64

```

1.6 BAB VI: Pra-Pelabelan Heuristik (*Rule-Based Labeling*)

Implementasi algoritma pencocokan kata kunci berdasarkan observasi *Ground Truth* awal untuk menyuntikkan label otomatis (setuju, batal, lainnya).

```

[33]: def rule_based_labeler(text):
        # Kata kunci khas dialek dan kebiasaan membalas
        kunci_batal = ['batal', 'cancel', 'kemahalan', 'mahal', 'ndak jadi', 'urung', 'skip', 'ambil aja', 'ambil yak', 'nanti dolok']
        kunci_setuju = ['lanjut', 'setuju', 'sikat', 'oke', 'boleh', 'iyak', 'ganti', 'kerjakan', 'aman', 'gas', 'baik', 'ok', 'iya', 'okey']

        if any(word in text for word in kunci_batal):
            return 'batal'
        elif any(word in text for word in kunci_setuju):
            return 'setuju'
        else:
            return 'lainnya'

df_pelanggan['intent'] = df_pelanggan['clean_text'].apply(rule_based_labeler)

distribusi_awal = df_pelanggan['intent'].value_counts()
print("=== HASIL PRA-PELABELAN OTOMATIS ===")
print(distribusi_awal)

# Visualisasi Ketimpangan Kelas
plt.figure(figsize=(7, 4))
bars = plt.bar(distribusi_awal.index, distribusi_awal.values, color='#888888', edgecolor='black', width=0.5)
plt.title('Visualisasi 2: Ketimpangan Kelas pada Master Data WA (Batal minoritas)', fontsize=12, fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center', va='bottom', fontweight='bold')
plt.show()

```


```

=== HASIL PRA-PELABELAN OTOMATIS ===
intent

```

```
lainnya      823
setuju       718
batal         40
Name: count, dtype: int64
```

Visualisasi 2: Ketimpangan Kelas pada Master Data WA (Batal minoritas)



```
[34]: # Mengekspor hasil pra-pelabelan mesin untuk divalidasi manual oleh Admin Toko
df_pelanggan.to_csv('data/hasil_prapelabelan_mesin.csv', index=False)
print("File CSV berhasil diekspor! Menunggu validasi Pakar...")
```

File CSV berhasil diekspor! Menunggu validasi Pakar...

```
[35]: # 1. Memuat data Master Chat yang sudah divalidasi pakar
df_validasi = pd.read_csv('data/master_chat_tervalidasi.csv')

print("=== SAMPEL DATA MASTER TERVALIDASI PAKAR ===")
display(df_validasi[['clean_text', 'intent']].sample(5, random_state=42))

# 2. Menghitung distribusi niat hasil validasi pakar
distribusi_validasi = df_validasi['intent'].value_counts()
print("\n=== DISTRIBUSI LABEL (TERVALIDASI PAKAR) ===")
print(distribusi_validasi)

# 3. Visualisasi Komparasi (Mesin vs Pakar)
# Catatan: Jika Anda tidak merubah label apapun di CSV secara manual, grafiknya
# akan terlihat identik.
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
```



```

# Chart Kiri: Tebakan Mesin (Variabel 'distribusi_awal' dari BAB VI)
axes[0].bar(distribusi_awal.index, distribusi_awal.values, color='#cccccc',
    ↪edgecolor='black', width=0.5)
axes[0].set_title('Tebakan Awal Mesin', fontsize=11, fontweight='bold')
axes[0].set_ylabel('Volume Data')
for bar in axes[0].patches:
    axes[0].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 5, int(bar.
    ↪get_height()), ha='center', va='bottom', fontweight='bold')

# Chart Kanan: Validasi Final Pakar
axes[1].bar(distribusi_validasi.index, distribusi_validasi.values,
    ↪color='#777777', edgecolor='black', width=0.5)
axes[1].set_title('Validasi Final Pakar (Ground Truth)', fontsize=11,
    ↪fontweight='bold')
for bar in axes[1].patches:
    axes[1].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 5, int(bar.
    ↪get_height()), ha='center', va='bottom', fontweight='bold')

plt.suptitle('Visualisasi Komparasi: Akurasi Tebakan Mesin vs Koreksi Manusia',
    ↪fontsize=14, fontweight='bold', y=1.05)
plt.tight_layout()
plt.show()

```

=== SAMPEL DATA MASTER TERVALIDASI PAKAR ===

	clean_text	intent
1124	besok buka jamber	setuju
813	tak bisa kurang lg k	lainnya
1175	diskon dikit boleh bg	setuju
534	baik bang	setuju
514	buka sampe jam berapa bg	lainnya


=== DISTRIBUSI LABEL (TERVALIDASI PAKAR) ===

```

intent
lainnya    823
setuju     718
batal      40
Name: count, dtype: int64

```

Visualisasi Komparasi: Akurasi Tebakan Mesin vs Koreksi Manusia



1.7 BAB VII: Konsolidasi Ekosistem WhatsApp Final

Data suplemen dari ekstraksi pakar (`data_baru_dari_wa_clean.csv`) digabungkan dengan `df_pelanggan` untuk menciptakan ekosistem obrolan WhatsApp yang tervalidasi secara utuh.

```
[37]: # 1. Memuat data suplemen WA
df_wa_suplemen = pd.read_csv('data/data_baru_dari_wa_clean.csv')

# 2. Standarisasi Teks Data Suplemen
df_wa_suplemen['clean_text'] = df_wa_suplemen['text'].apply(text_normalization)
df_wa_suplemen['intent'] = df_wa_suplemen['intent'].astype(str).str.lower().str.strip()

# 3. MENGAMBIL 4 KOLOM EMAS & MENYUNTIKKAN SUMBER (SOURCE)
# Untuk master chat (kita ubah nama 'Message Body' menjadi 'text' agar seragam)
df_wa_utama = df_validasi[['Message Body', 'clean_text', 'intent']].copy()
df_wa_utama = df_wa_utama.rename(columns={'Message Body': 'text'})
df_wa_utama['source'] = 'master_chat'

# Untuk data suplemen
df_wa_suplemen_bersih = df_wa_suplemen[['text', 'clean_text', 'intent']].copy()
df_wa_suplemen_bersih['source'] = 'suplemen_wa'

# 4. Peleburan (Concatenation) & Hapus Duplikasi
df_wa_final = pd.concat([df_wa_utama, df_wa_suplemen_bersih], ignore_index=True)
df_wa_final = df_wa_final.drop_duplicates(subset=['clean_text', 'intent'])
df_wa_final = df_wa_final[df_wa_final['clean_text'] != ''] # Hapus string kosong

# 5. EKSPOR KE CSV FINAL WA
df_wa_final.to_csv('data/dataset_wa_final.csv', index=False)
```

```

print("=== EKSPOR BERHASIL: dataset_wa_final.csv ===")

distribusi_wa_final = df_wa_final['intent'].value_counts()
print(f"Total Baris Ekosistem WA Tervalidasi: {len(df_wa_final)} Baris\n")


# Visualisasi Ekosistem WA
plt.figure(figsize=(8, 5))
bars = plt.bar(distribusi_wa_final.index, distribusi_wa_final.values,
               color='#777777', edgecolor='black', linewidth=1.5, width=0.5)
plt.title('Visualisasi 3: Distribusi Niat pada Ekosistem WhatsApp Tervalidasi',
         fontsize=13, fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
for bar in bars:
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center',
            va='bottom', fontweight='bold')
plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()

```

```

=== EKSPOR BERHASIL: dataset_wa_final.csv ===
Total Baris Ekosistem WA Tervalidasi: 1364 Baris

```



1.8 BAB VIII: Integrasi Data Primer (Kuesioner Dialek)

Data hasil penyebaran kuesioner memiliki struktur *Wide-Format* (horizontal) di mana satu responden mengisi enam skenario jawaban. Agar dapat dilatih oleh model *Machine Learning*, data ini harus dikonversi menjadi *Long-Format* (vertikal) melalui proses *Data Melting*. Selanjutnya, data ini akan distandarisasi menggunakan fungsi `text_normalization` yang sama dengan ekosistem WhatsApp demi menjaga konsistensi matriks fitur teks.

```
[39]: # 1. Memuat file raw kuesioner
path_kuesioner = 'data/
↳Pengumpulan_Data_Linguistik_Interaksi_Layanan_Pelanggan_untuk_Pelatihan_Model_Natural_Langu
↳csv'
df_raw_kuesioner = pd.read_csv(path_kuesioner)

print("=== BENTUK ASLI DATA KUESIONER (WIDE FORMAT) ===")
# Tampilkan 3 baris saja sudah cukup untuk melihat betapa panjangnya data
↳menyamping
display(df_raw_kuesioner.head(3))
```

=== BENTUK ASLI DATA KUESIONER (WIDE FORMAT) ===

```
Timestamp 1. Rentang Usia: \
0 14/08/2026 9:09:00      >35 Tahun
1 14/08/2026 9:13:00    18 - 25 Tahun
2 14/08/2026 9:53:00      >35 Tahun
```

```
2. Tingkat pemahaman dan penggunaan dialek Melayu Pontianak dalam komunikasi
↳pesan teks: \
0                                Aktif (Sering menggunakan)
1                                Aktif (Sering menggunakan)
2                                Aktif (Sering menggunakan)
```

```
1. Tuliskan balasan singkat secara natural jika penawaran biaya tersebut
↳disetujui. \
0                                okeh
1                                boleh kak
2                                Lanjut pak
```

```
2. Tuliskan balasan persetujuan dengan menggunakan dialek Melayu Pontianak
↳secara kental... \
0 Sikat jak bang, tpi saye nak nunggu disitok bi...
1 Sikat jak bang, tpi saye nak nunggu disitok bi...
2 Gass bah min, cepatkan sikit ye soale saye nak...
```

```
3. Tuliskan balasan singkat secara natural jika biaya ditolak dan unit ingin
↳diambil kembali. \
0                                Batal jak bang
1                                gk jd
2                                Batal
```

4. Tuliskan balasan pembatalan perbaikan dengan menggunakan dialek Melayu Pontianak... \
- ```
0 Tunda lok pak, nnti mun ade rezeki saye balek ...
1 Aduh duit saye tak cukup bg, ambek lok lah nnti
2 nd usah bang. agek butuh makai banyak duet
```
5. Tuliskan balasan yang secara spesifik memuat negosiasi atau tawar-menawar harga perbaikan. \
- ```
0 Hargenye bise turun sikit ndak min?
1 Nda bise kurang hargenye tu bang?
2 Nd bise kurang ke bang hargenye tu?
```
6. Tuliskan balasan yang mempertanyakan durasi atau estimasi waktu pengerjaan...
- ```
0 Bang mun nak betolkan laptop kire-kire sampai ...
1 Kak lokasi pastinya di belah mane ye?
2 Bg nnti malam bukak ndak?
```

```
[40]: # Kita ambil HANYA nama-nama kolom yang berisi teks jawaban (indeks ke-3 sampai
 ↪ batas ke-9)
```

```
kolom_teks = df_raw_kuesioner.columns[3:9]

print("=== 6 KOLOM PERTANYAAN YANG AKAN DILELEHKAN ===")
for i, col in enumerate(kolom_teks):
 print(f"{i+1}. {col}")
```

```
=== 6 KOLOM PERTANYAAN YANG AKAN DILELEHKAN ===
```

1. 1. Tuliskan balasan singkat secara natural jika penawaran biaya tersebut disetujui.
2. 2. Tuliskan balasan persetujuan dengan menggunakan dialek Melayu Pontianak secara kental...
3. 3. Tuliskan balasan singkat secara natural jika biaya ditolak dan unit ingin diambil kembali.
4. 4. Tuliskan balasan pembatalan perbaikan dengan menggunakan dialek Melayu Pontianak...
5. 5. Tuliskan balasan yang secara spesifik memuat negosiasi atau tawar-menawar harga perbaikan.
6. 6. Tuliskan balasan yang mempertanyakan durasi atau estimasi waktu pengerjaan...

```
[41]: # Fungsi 'melt' meruntuhkan 6 kolom menyamping menjadi format vertikal
```

```
df_kuesioner_melted = df_raw_kuesioner.melt(
 id_vars=[],
 value_vars=kolom_teks,
 var_name='pertanyaan',
 value_name='text'
)
```

```
print("=== HASIL SETELAH DILELEHKAN (LONG FORMAT) ===")
Jumlah baris seharusnya menjadi 103 responden x 6 pertanyaan = 618 baris
print(f"Jumlah baris sekarang: {len(df_kuesioner_melted)}")
display(df_kuesioner_melted.head(5))
```

=== HASIL SETELAH DILELEHKAN (LONG FORMAT) ===

Jumlah baris sekarang: 618

|   | pertanyaan                                        | text       |
|---|---------------------------------------------------|------------|
| 0 | 1. Tuliskan balasan singkat secara natural jik... | okeh       |
| 1 | 1. Tuliskan balasan singkat secara natural jik... | boleh kak  |
| 2 | 1. Tuliskan balasan singkat secara natural jik... | Lanjut pak |
| 3 | 1. Tuliskan balasan singkat secara natural jik... | lanjut bg  |
| 4 | 1. Tuliskan balasan singkat secara natural jik... | Boleh bg   |

[42]: # Membuat kamus pemetaan manual berdasarkan urutan 6 kolom pertanyaan tadi

```
mapping_intent = {
 kolom_teks[0]: 'setuju',
 kolom_teks[1]: 'setuju',
 kolom_teks[2]: 'batal',
 kolom_teks[3]: 'batal',
 kolom_teks[4]: 'lainnya',
 kolom_teks[5]: 'lainnya'
}

1. Suntik label dengan cara menerjemahkan kolom 'pertanyaan'
df_kuesioner_melted['intent'] = df_kuesioner_melted['pertanyaan'].
 ↪map(mapping_intent)

2. Membersihkan data yang kosong (jika ada responden yang tidak mengisi)
df_kuesioner_melted = df_kuesioner_melted.dropna(subset=['text']).copy()

3. Terapkan Standarisasi (rumus andalan kita)
df_kuesioner_melted['clean_text'] = df_kuesioner_melted['text'].
 ↪apply(text_normalization)

4. Suntik sumber data
df_kuesioner_melted['source'] = 'kuesioner'

5. Bungkus dan ambil 4 Kolom Emas
df_kuesioner_final = df_kuesioner_melted[['text', 'clean_text', 'intent',
 ↪'source']].copy()

print("=== HASIL AKHIR EKSTRAKSI DATA KUESIONER ===")
display(df_kuesioner_final.sample(5, random_state=42))
```

=== HASIL AKHIR EKSTRAKSI DATA KUESIONER ===

text \

```

49 Sip
582 Kak lokasi pastinya di belah mane ye?
82 Okey
305 cancell ajaa min
109 Aok min, kerjekan jak lok. Tpi jangan diinstal...

```

```

 clean_text intent source
49 sip setuju kuesioner
582 kak lokasi pastinya di belah mane ye lainnya kuesioner
82 okey setuju kuesioner
305 cancell ajaa min batal kuesioner
109 aok min kerjekan jak lok tpi jangan diinstal u... setuju kuesioner

```

```

[43]: # Menghitung distribusi niat pada data kuesioner
distribusi_kuesioner = df_kuesioner_final['intent'].value_counts()

print("=== DISTRIBUSI LABEL KUESIONER ===")
print(distribusi_kuesioner)

Membuat Bar Chart Monokrom
plt.figure(figsize=(7, 5))
bars = plt.bar(distribusi_kuesioner.index, distribusi_kuesioner.values,
 color='#888888', edgecolor='black', width=0.5)

plt.title('Visualisasi 4: Distribusi Niat pada Data Kuesioner (Sangat
 Seimbang)', fontsize=12, fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat', fontsize=11)
plt.ylabel('Volume Data', fontsize=11)
plt.ylim(0, max(distribusi_kuesioner.values) + 30) # Memberi ruang agar angka
 tidak menabrak atap grafik

for bar in bars:
 yval = bar.get_height()
 plt.text(bar.get_x() + bar.get_width()/2, yval + 5, int(yval), ha='center',
 va='bottom', fontweight='bold')

plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()


```

```

=== DISTRIBUSI LABEL KUESIONER ===
intent
setuju 206
batal 206
lainnya 206
Name: count, dtype: int64

```

**Visualisasi 4: Distribusi Niat pada Data Kuesioner (Sangat Seimbang)**



## 1.9 BAB IX: Fusi Ekosistem WA dan Kuesioner (Dataset Siap Latih)

Tahap prapemrosesan diakhiri dengan menggabungkan dataset historis WhatsApp yang mencerminkan interaksi natural, dengan dataset Kuesioner yang memperkaya ragam dialek dan mengangkat volume kelas minoritas. Dataset gabungan ini diekspor menjadi matriks akhir yang siap dilatih oleh algoritma NLP.

```
[44]: # 1. Memuat kembali data WA Final (Titik Aman Sebelumnya)
df_wa_final = pd.read_csv('data/dataset_wa_final.csv')

2. Penggabungan (Concatenation) WA dan Kuesioner
df_siap_latih = pd.concat([df_wa_final, df_kuesioner_final], ignore_index=True)

3. Menghapus duplikasi silang (barangkali ada kalimat kuesioner yang persis
↳ sama dengan WA)
df_siap_latih = df_siap_latih.drop_duplicates(subset=['clean_text', 'intent']).
↳ copy()

4. EKSPOR KE CSV FINAL (DATASET SIAP LATIH)
df_siap_latih.to_csv('data/dataset_siap_latih_final.csv', index=False)
print("=== EKSPOR BERHASIL: dataset_siap_latih_final.csv ===")
```



```

5. Visualisasi Distribusi Final (Untuk Menentukan Tindakan di Tahap Training)
distribusi_siap_latih = df_siap_latih['intent'].value_counts()
print("\n=== DISTRIBUSI LABEL FINAL (SIAP LATIH) ===")
print(distribusi_siap_latih)

plt.figure(figsize=(8, 5))
bars = plt.bar(distribusi_siap_latih.index, distribusi_siap_latih.values,
 color='#555555', edgecolor='black', linewidth=1.5, width=0.5)

plt.title('Visualisasi 5: Distribusi Final Dataset Siap Latih (WA +
Kuesioner)', fontsize=13, fontweight='bold', pad=15)
plt.xlabel('Kategori Label Niat')
plt.ylabel('Volume Data')
plt.ylim(0, max(distribusi_siap_latih.values) + 150) # Ruang ekstra

for bar in bars:
 yval = bar.get_height()
 plt.text(bar.get_x() + bar.get_width()/2, yval + 10, int(yval),
 ha='center', va='bottom', fontweight='bold')

plt.grid(axis='y', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()

```

=== EKSPOR BERHASIL: dataset\_siap\_latih\_final.csv ===

=== DISTRIBUSI LABEL FINAL (SIAP LATIH) ===

```

intent
lainnya 836
setuju 616
batal 93
Name: count, dtype: int64

```

**Visualisasi 5: Distribusi Final Dataset Siap Latih (WA + Kuesioner)**

